

ML_HW4 / 機器學習智慧系統

作業編號:	04
學生姓名:	許允誠
系級:	財金三
學號:	112408540

目錄

目錄.....	1
壹、 演算法 A 實作：純鯨群最佳化演算法（純 WOA）訓練 NFS.....	2
1.1 類神經模糊系統（NFS）模型建立與資料前處理.....	2
貳、 演算法 B 實作：混合式演算法（混合式 WOA-RLSE）訓練 NFS.....	5
2.1 混合式演算法之問題敘述與目標.....	5
2.2 遞歸最小平方法（RLSE）理論與參數設定.....	5
參、 結論與心得.....	7
3.1 核心實驗結果深度分析：學習曲線之成果.....	7
3.3 心得與反思.....	10
肆、 參考文獻.....	12

壹、演算法 A 實作：純鯨群最佳化演算法（純 WOA）訓練 NFS

1.1 類神經模糊系統（NFS）模型建立與資料前處理

本章節的目標在於建構一個從零開始實作的 Sugeno-Takagi (T-S) 類神經模糊系統 (Neuro-Fuzzy System, NFS)，並將其應用於台灣加權股價指數 (TWII) 之時間序列預測。

(1) 資料前處理與監督式學習對建構

本實作所使用的數據集為 2025 年台灣加權股價指數之每日收盤價。為了符合機器學習之監督式學習 (Supervised Learning) 架構，必須將原始的一維時間序列資料轉換為特徵輸入與標籤輸出的數據對 (Data pairs)。

依據作業規範，本系統設定為「2 個模型輸入、1 個模型輸出」。轉換邏輯如下：利用前兩日的真實收盤價 $[x_i, x_{i+1}]^T$ 作為網路輸入，用以預測第三日的收盤價 x_{i+2} (即 $\hat{x}_{i+2}$)。資料集切分方式為：取資料集前 200 筆數據對作為訓練階段 (Training Set) 的樣本，用以更新優化模型參數；剩餘的資料對則全數歸為測試階段 (Testing Set)，用以評估模型之泛化能力與預測準確度。

(2) NFS 網路架構與參數數量計算

本 NFS 模型由 6 層神經網路結構所組成，並包含 16 條 T-S 模糊 If-Then 規則 ($K=16$)。其數學架構與待優化參數總量詳細剖析如下：

- **前鑑部 (If-part) 參數：** 輸入空間共有 2 個維度 (x_1, x_2)，每條規則在各維度均配置一個高斯隸屬函數 (Gaussian Membership Function)。高斯函數由兩個核心參數決定：中心值 (Mean, c) 與標準差 (Standard Deviation, σ)。

因此，前鑑部待優化之總參數計有 $2*16*2=64$

- **後鑑部 (Then-part) 參數：** 每條規則的結論層均採用一階線性多項式 (First-order Polynomial)。針對 2 維輸入，單一規則的輸出方程式為

$$f^k = a_0^k + a_1^k x^1 + a_2^k x^2$$

其中包含 3 個係數 (a_0, a_1, a_2)。因此，待優化之總參數計有 $16*3=48$ 個。

綜上所述，整個類神經模糊系統在未實施任何參數分解前，總計包 64+48=112 個高度非線性的待訓練參數。

1.2 理論方法與純 WOA 參數設定

在演算法 A 之中，我們將上述 112 個參數視為一個整體的、高維度的無導數最佳化 (Derivative-free Optimization) 問題，完全交由**純鯨群最佳化演算法 (Whale Optimization Algorithm, WOA)** 進行全域尋優。

(1) 純 WOA 優化機理

WOA 演算法是模擬座頭鯨獵食行為的元啟發式演算法，其核心數學模型包含三大階段：

1. **包圍獵物 (Shrinking Encircling Mechanism)**：粒子透過當前最佳解 (Leader) 的位置進行位置更新，由控制參數 A 與 C 進行收縮幅度調節。
2. **泡泡網攻擊 (Spiral Updating Position)**：模擬鯨魚以螺旋路徑向獵物逼近，透過對數螺旋方程式建立數學模型。
3. **尋找獵物 (Search for Prey / Exploration)**：當 $|A| \geq 1$ 時，粒子強制隨機選擇群體中的其他鯨魚作為參考基準，以增強演算法之全域探索能力，避免陷入局部最佳解 (Local Minima)。

(2) 損失函數 (Loss Function / Fitness Function)

本實作之適應度函數 (Fitness Function) 採用**均方誤差 (Mean Squared Error, MSE)**。每一隻鯨魚的位置向量 (112 維) 會被解碼並寫入 NFS 的各層權重中。透過前向傳播 (Forward Propagation) 計算預測值與真實股價的落差：

$$MSE = \frac{1}{N} \sum_{i=1}^N (x_{i+2} - \hat{x}_{i+2})^2$$

WOA 的尋優目標即為最小化 (Minimize) 此損失函數。

(3) 超參數與環境設定

依據助教與作業規範之嚴格要求，演算法 A 的超參數設定如下表所示：

Hyperparameters	Value	Description
鯨魚粒子數量	60	確保在高維空間中有足夠的群體多樣性
最大疊代次數	3000	提供純啟發式演算法足夠的收斂時間
搜尋空間邊界限制	$c \in [20000, 30000]$ $\sigma \in [100, 5000]$ $a \in [-10, 10]$	依股價之量級與高斯函數分佈進行合理界定




圖 1：演算法 A（純 WOA）於 3000 次疊代之學習曲線收斂圖

貳、演算法 B 實作：混合式演算法（混合式 WOA-RLSE）訓練 NFS

2.1 混合式演算法之問題敘述與目標

在演算法 A 中，純 WOA 必須同時在 112 維的高維空間中搜尋全域最佳解。然而，啟發式演算法在處理包含高度非線性與線性混合的龐大參數時，容易面臨收斂速度緩慢或陷入局部最佳解的瓶頸。

為了解決此問題，我們引入了「混合式學習（Hybrid Machine Learning）」的架構。根據類神經模糊系統（NFS）的特性，只要前鑑部（If-part）的非線性參數（高斯函數之 c 與 σ ）被給定，經過網路層次計算至第 4 層的正規化激發強度（Normalized Firing Strength, $\bar{w}^k$ ）成為常數。此時，整個系統的輸出便退化為後鑑部（Then-part）參數的線性組合。

因此，混合式演算法 B 的核心分工目標為：

1. 非線性尋優（WOA 負責）：利用 WOA 強大的全域探索能力，專職訓練 If-part 的 64 個參數。
2. 線性解析（RLSE 負責）：在 WOA 決定 If-part 參數後，利用遞歸最小平方方法（Recursive Least Squares Estimator, RLSE）精準、迅速地直接推導出 Then-part 的 48 個最佳線性參數，徹底免除對 Then-part 的盲目隨機搜尋。

2.2 遞歸最小平方方法（RLSE）理論與參數設定

遞歸最小平方方法（RLSE）是一種基於線性代數與誤差最小化的自適應濾波演算法。相較於標準 LSE 需要一次性反轉龐大的資料矩陣，RLSE 允許資料逐筆（Recursive）輸入，並即時更新參數矩陣 θ （即我們的 Then-part 多項式係數），大幅降低記憶體負載與運算複雜度。

(1) RLSE 數學更新公式

令 θ 為欲求之參數向量， $\mathbf{a}_i$ 為第 i 筆資料經過 Layer 4 計算後結合輸入的特徵向量， $\mathbf{y}_i$ 為真實目標值。RLSE 的遞歸步驟如下

1. 計算增益矩陣 (Gain Matrix): $K_i = \frac{P_{i-1}a_i}{1+a_i^T P_{i-1}a_i}$

2. 更新參數向量: $\theta_i = \theta_{i+1} + K(y_i - a_i^T \theta_{i-1})$

3. 更新協方差矩陣: $P_i = P_{i-1} - K_i a_i^T P_{i-1}$

(2) 演算法 B 參數與初始條件設定

依據作業規範與課堂講義，RLSE 的初始狀態必須給定一個極大的對角矩陣以代表初始的不確定性；同時，由於 RLSE 分擔了近一半的優化工作，WOA 的疊代負擔得以大幅減輕。具體設定如下表：

模組	Hyperparameters	Value	說明
RLSE	初始協方差矩陣 (P_0)	αI , $\alpha = 1 * 10^9$	I 為 48x48 單位矩陣，代表極大的初始權重調整空間
RLSE	初始參數向量 (θ_0)	Zero vector	48 維的全零向量
WOA	鯨魚粒子數量 (n_{WOA})	30	因參數降至 64 維，僅需 30 隻粒子即可維持多樣性
WOA	最大疊代次數 (n_r)	1000	有 RLSE 輔助，收斂速度極快，故疊代次數設為 1000 次




圖 2：演算法 B（混合式 WOA-RLSE）於 1000 次疊代之學習曲線收斂圖

參、結論與心得

3.1 核心實驗結果深度分析：學習曲線之成果

本章節首先針對實驗所產出之兩大核心圖表——「演算法 A（純 WOA）學習曲線」與「演算法 B（混合式 WOA-RLSE）學習曲線」進行定量與定性的深度行為分析，探討其收斂軌跡背後所隱含的機器學習優化機理。

(1) 演算法 A（純 WOA）的漸進式階梯收斂軌跡分析

- **探索與收斂行為：**在 3000 次的漫長疊代過程中，曲線在特定區間會陷入長時間的平台期（Plateau），隨後因部分鯨魚粒子成功觸發「尋找獵物（Exploration）」或「對數螺旋更新（Exploitation）」而突破局部極值，使 MSE^* 產生階梯式的向下躍遷。
- **維度災難（Curse of Dimensionality）之體現：**由於純 WOA 必須同時在一個高達 112 維的混合參數空間（包含 64 個前鑑部非線性參數與 48 個後鑑部線性參數）進行黑盒尋優（Derivative-free Optimization），無導數資訊的隨機擾動使得演算法在後期極難同時協調非線性隸屬函數與線性結論多項式。這解釋了為何演算法 A 需要耗費高達 3000 代的運算資源，且其最終的收斂斜率在後期顯得極為平緩。




圖 3：演算法 A（純 WOA）於訓練階段（前 200 筆）之股價預測擬合圖




圖 4：演算法 A（純 WOA）於測試階段（樣本外）之股價預測擬合圖

(2) 演算法 B（混合式 WOA-RLSE）的斷崖式超越收斂與解析解優勢

相較之下，演算法 B 的學習曲線則展現出完全不同的「斷崖式（Precipitous Drop）」收斂行為，其優化效率產生了質的飛躍。

- **斷崖式收斂機理：**從圖表中可以清晰看見，在疊代極早期的前數十代內， $MSE(q)$ 便以幾近垂直的角度瞬間崩跌至極低點，並在後續的 1000 代中展現出極度穩定的收斂平台。此現象完美視覺化了李教授課堂講義中 "Hybrid Learning for NFSs" 的核心精髓。
- **參數空間分解（Decomposition of Parametric Subspaces）的威力：**在混合編碼架構下，當 WOA 粒子在初期隨機初始化或輕微擾動 Subset-1（64 維 If-part 非線性參數）時，系統隨即將資料前向傳播至第四層（Layer 4）。此時，後鑑部的參數優化便被限縮於一個標準的線性子空間中。系統不需透過 WOA 盲目猜測，而是直接呼叫 **遞歸最小平方法（RLSE）**，在當代立刻解析出讓該結構誤差達到數學絕對最小化的 Subset-2（48 維 Then-part 線性參數）。
- **優化效率總結：**這種「WOA 負責提出非線性框架，RLSE 負責填入完美線性解」的機制，等同於抹去了近半數的搜尋維度，使演算法 B 僅需 1000 次疊代（甚至在 100 代內已實質收斂），其最終所達到的 Train MSE 與收斂速度皆大幅超越了純 WOA。




圖 5：演算法 B（混合式 WOA-RLSE）於訓練階段（前 200 筆）之股價預測擬合圖




圖 6：演算法 B（混合式 WOA-RLSE）於測試階段（樣本外）之股價預測擬合圖

3.2 演算法 A 與演算法 B 之效能對比

在完成學習曲線的視覺化分析後，本節將進一步從量化指標（Train MSE 與 Test MSE）與模型泛化能力（Generalization）的角度，對純 WOA 與 WOA-RLSE 進行綜合效能比較。

表 1：演算法效能與預測誤差比較表

評估指標 (Metrics)	演算法 A (純 WOA)	演算法 B (WOA- RLSE)	效能差異分析
總疊代次數 (n_T)	3000 次	1000 次	B 演算法大幅減少了 66% 的疊

			代需求
優化參數維度	112 維 (If + Then)	64 維 (僅 If-part)	B 演算法藉由 RLSE 成功降維
Train MSE (訓練集)	116555.47	54915.75	B 的誤差顯著低於 A
Test MSE (測試集)	109110.94	103586.51	B 展現出更佳的樣本外預測能力

根據上述量化數據與前面的預測疊合圖，我們可以歸納出：

參數空間的「降維打擊」優勢：純 WOA 在處理 112 維參數時，容易產生「維度災難」，導致粒子在龐大的搜索空間中迷失，難以同時顧及隸屬函數的形狀與輸出多項式的權重。演算法 B 巧妙地利用了 NFS 第四層（激發強度正規化）的轉折點，將問題切分為「非線性尋優」與「線性解析」兩個獨立子空間。這種「參數分解」不僅減輕了 WOA 的負擔，更確保了 Then-part 參數的絕對最佳性。

泛化能力 (Generalization) 的提升：觀察 Test MSE 的表現，演算法 B 通常能取得更低的測試誤差。這是因為純 WOA 在後期為了微調 MSE，容易在訓練集上產生過擬合 (Overfitting) 的盲目擾動；而 RLSE 則是基於嚴謹的線性代數推導，以最小化整體平方誤差為目標，其解出的多項式係數更具備全局的平滑性與穩定性，進而提升了模型在面對未知的 TWII 未來股價時的預測準確度。

3.3 心得與反思

本次「類神經模糊系統與混合式機器學習」的實作，是一次從底層架構到高階優化演算法的深度洗禮。在建構 NFS 的過程中，我深刻體會到將「模糊邏輯的推論解釋性」與「類神經網路的自適應學習力」結合的精妙之處。傳統神經網路往往被詬病為黑盒子 (Black-box)，但 NFS 透過 T-S If-Then 規則，讓我們能清晰定義前鑑部與後鑑部的數學意義。

而在演算法的比較上，本次作業帶給我最大的震撼在於「**數學解析解在機器學習中的不可取代性**」。近年來，隨著深度學習與啟發式演算法的盛行，人們習慣將所有問題丟給 GPU 進行暴力疊代尋優。然而，李教授課堂上所教授的 "Hybrid Learning for NFSs" 架構卻提醒了我們：「**能夠用數學公式直接解出來的最佳解，就不應該交給隨機演算法去瞎猜。**」遞歸最小平方方法 (RLSE) 的導入，完美詮釋了這句話的價值。它讓原本在 3000 代中掙扎求生的 WOA，瞬

間在幾十代內達到了前所未有的收斂深度。這不僅大幅節省了運算資源，更提升了預測的精準度。身為財金系的學生，這次實作讓我認知到，在面對如台灣加權指數（TWII）這類充滿雜訊與高度非線性的金融時間序列時，除了仰賴強大的 AI 模型，選擇對的「優化策略（Optimization Strategy）」與「參數分解邏輯」，才是決定量化預測模型成敗的真正關鍵。

肆、參考文獻

- [1]李俊賢 (2026)。《機器學習智慧系統課堂講義：Lecture - Neuro-Fuzzy Systems (NFSs) and Hybrid Machine Learning (類神經模糊系統與混合式機器學習)》。國立中央大學資訊管理學系。
- [2]李俊賢 (2026)。《機器學習智慧系統課堂講義：Lecture - Metaheuristic Methods for Machine Learning (Part-1) (機器學習的啟發式演算法, Part-1)》。國立中央大學資訊管理學系。
- [3]李俊賢 (2026)。《機器學習智慧系統課堂講義：Lecture - Fuzzy Sets and Fuzzy Inference Systems (模糊集合及模糊推理系統) [united version]》。國立中央大學資訊管理學系。
- [4]李俊賢 (2026)。《機器學習智慧系統課堂講義：Lecture - AI_an_overview (人工智慧簡論)》。國立中央大學資訊管理學系。
- [5]李俊賢 (2026)。《機器學習智慧系統課堂講義：Lecture - Clustering for Machine Learning (機器學習的分群方法)》。國立中央大學資訊管理學系。